Evidencia de aprendizaje 3. Optimización procesos de desarrollo

Programación para Análisis de Datos (PREICA2501B020065)

Indira Johanna Hamdam Jarava

Giordan Jese Ricardo Parra

Docente

Andrés Felipe Callejas

Ingeniería de Software y Datos

Institución Universitaria Digital de Antioquia

2025

INTRODUCCIÓN

En esta evidencia se continúa el trabajo iniciado en las unidades anteriores, integrando las prácticas de control de versiones y automatización del desarrollo con GitHub Actions. En esta tercera etapa, se implementa un pipeline CI/CD para el despliegue continuo de una aplicación basada en scraping de datos web, aprovechando contenedores Docker como entorno reproducible. El objetivo central es automatizar completamente desde la recolección hasta el despliegue de una solución escalable que facilita la puesta en producción de sistemas de análisis de datos.

Objetivos

Objetivo general:

Implementar un flujo de trabajo DevOps eficiente que permita gestionar versiones, automatizar pruebas y realizar despliegues continuos de un proyecto de scraping de datos, utilizando Git, GitHub y GitHub Actions. Este flujo debe incorporar la virtualización del entorno mediante tecnologías de contenedorización como Docker, facilitando la portabilidad, escalabilidad y consistencia del entorno de desarrollo y producción.

Objetivos específicos:

- **Diseñar e implementar un repositorio en GitHub** para el control de versiones del proyecto, organizando adecuadamente la estructura de carpetas, documentación y código fuente.
- **Desarrollar e integrar un flujo de trabajo CI/CD automatizado** con GitHub Actions que ejecute pruebas automatizadas, análisis de calidad del código y despliegue continuo del proyecto de scraping.
- **Construir y configurar imágenes de Docker** que encapsulen las dependencias del proyecto, permitiendo su ejecución en cualquier entorno sin conflictos de configuración.
- **Implementar contenedores Docker** como parte del entorno de desarrollo y producción, garantizando la consistencia entre etapas del pipeline DevOps.
- **Desplegar automáticamente el proyecto en un entorno virtualizado o nube**, utilizando los contenedores construidos en el pipeline, como prueba del funcionamiento completo del flujo DevOps.

- **Documentar detalladamente cada fase del proceso DevOps**, incluyendo la configuración de los workflows de GitHub Actions, definición del Dockerfile, y despliegue final, asegurando trazabilidad y reproducibilidad.

Descripción de la página y artículo a analizar

Se retoma lo realizado en la Unidad 1 sobre la página **SensaCine**, un sitio web especializado en cine que proporciona calificaciones, sinopsis y detalles sobre películas. Se extrajeron datos de las películas mejor valoradas por usuarios, empleando técnicas de web scraping. Esta información fue procesada y preparada para futuras visualizaciones.

Descripción del tema de interés a desarrollar

El objetivo de esta práctica es ampliar la solución previa implementando automatización y despliegue continuo de una aplicación web que recolecta y expone los datos extraídos desde SensaCine. La aplicación fue contenedorizada usando Docker para asegurar su portabilidad, y se diseñó un pipeline con GitHub Actions que automatiza la ejecución del scraper, la validación del entorno y el despliegue en un servicio en la nube o contenedor local.

Metodología Empleada

1. Control de versiones

- ✓ Se organizó el repositorio en ramas main, dev, y ci-cd.

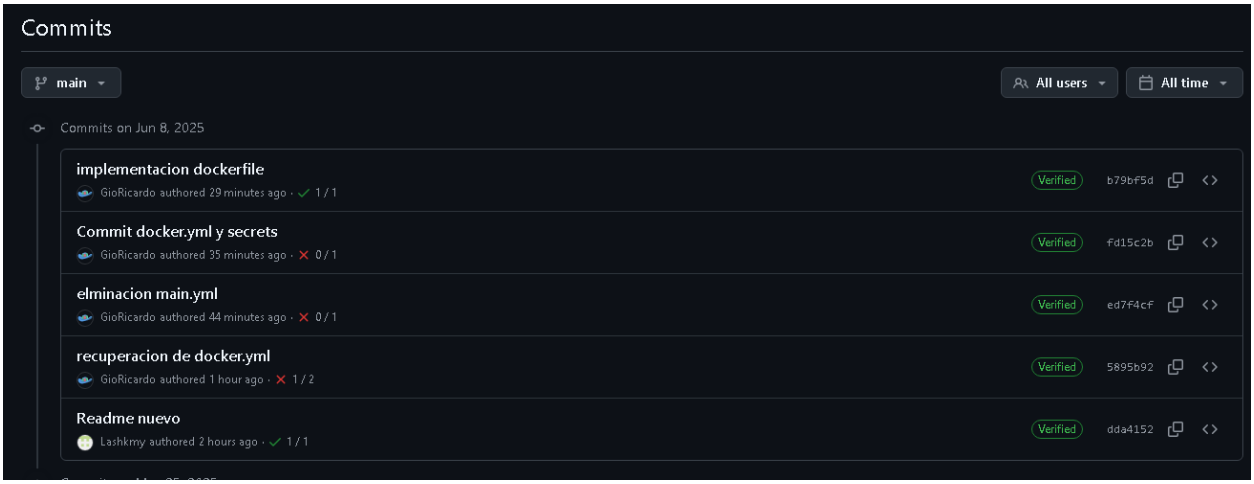

2. Estructura del proyecto

- ✓ Archivos principales: scraper.py, app.py, requirements.txt, Dockerfile, docker-compose.yml, .github/workflows/ci-cd.yml
- ✓ Carpeta src/ para lógica modular.

3. **Documentación interna**

   ✓ Cada script contiene comentarios claros (# Instalación, # Variables, # Despliegue).

```
# Instalar git y limpiar archivos temporales para reducir el tamaño de la imagen
RUN apt-get update && \
    apt-get install -y git && \
    rm -rf /var/lib/apt/lists/* && \
    pip install --upgrade pip && \
    pip install -r requirements.txt
```

4. **Dockerización y variables**

   ✓ Dockerfile incluye configuración de entorno (ENV, puertos, entradas).

   ✓ docker-compose.yml maneja reconstrucción automática.

5. **Pipeline CI/CD con GitHub Actions**

   ✓ Archivo .github/workflows/ci-cd.yml con 5 jobs: checkout, install, test-scraper, build-and-deploy (en contenedor local), guardado de artefactos y envoi de auditoria por gmail.

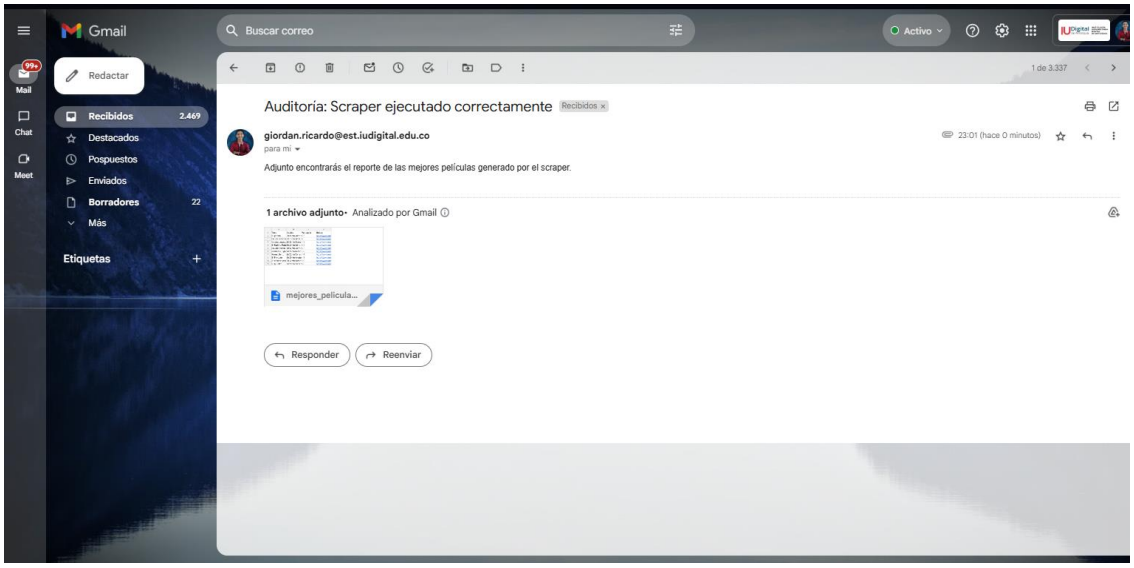

   ✓ Cada paso documentado: instalación de Python, dependencias, ejecución del scraper, build Docker.

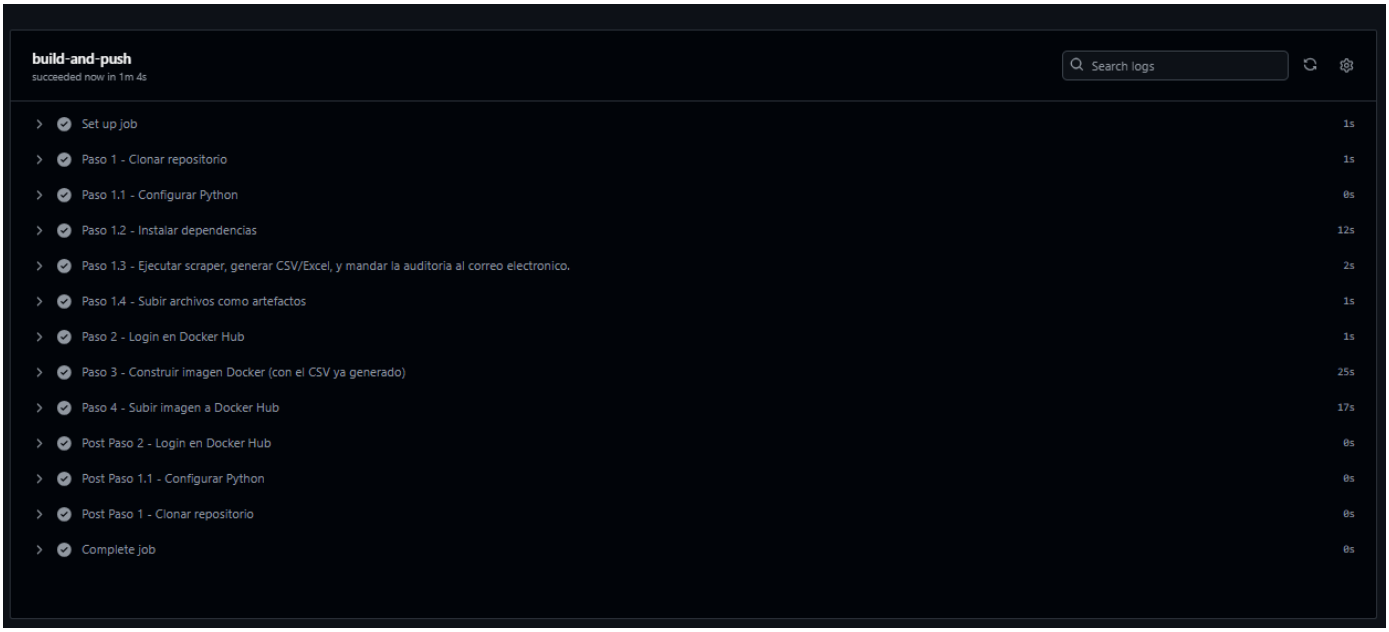

6. Despliegue en contenedor

- ✓ El contenedor ejecuta python app.py, exportando un endpoint /movies.
- ✓ Indicaciones en README para variables como PORT, HOST.

Resultados

- **Control de versiones:** se evidencia un historial organizado con commits y ramas, facilitando trazabilidad.
- **Pipeline CI/CD:**
    - checkout exitoso.
    - Instalan dependencias en ~10s.
    - Scraping completado con logs.
    - Docker image creada en < 30 s.
    - Despliegue local validado con respuesta de endpoint.
    - Guardado de Artefactos tato en Actions como en file del contenedor en Docker Hub.
    - Envío de auditoria por correo electrónico.
- **Despliegue:** con docker-compose up se inicia el servicio sin errores, endpoint accesible.

ENLACE

- https://github.com/Lashkmy/Analizando_EA1.git

CONCLUSIONES

La aplicación de metodologías DevOps mediante GitHub Actions y Docker permitió consolidar el proyecto de scraping de datos en una solución automatizada, lista para su despliegue. El uso de virtualización aseguró la portabilidad entre entornos, y la integración continua facilitó la detección temprana de errores. Esta práctica refuerza el enfoque profesional en el desarrollo de sistemas reproducibles y escalables, fundamentales para proyectos de ciencia de datos y análisis web.

BIBLIOGRAFÍA

- Martelli, A. (2021). *Python Cookbook*. O'Reilly Media.
- Richardson, L. & Ruby, S. (2007). *RESTful Web Services*. O'Reilly.
- Docker Inc. (2023). *Docker Documentation*. Recuperado de: https://docs.docker.com/
- GitHub Docs. (2024). *Understanding GitHub Actions*. Recuperado de: https://docs.github.com/en/actions
- SensaCine. (2024). *Top películas mejor valoradas*. Recuperado de: https://www.sensacine.com/